

Clasificación de Rentabilidad en Ventas con Árboles de Decisión y Naive Bayes sobre el Dataset "Superstore"

Ing. Percy Pedro Fuentes Ramos

Universidad Mayor de San Andrés, Bolivia

Resumen

Este trabajo presenta un análisis de rentabilidad de ventas utilizando algoritmos de clasificación sobre un dataset de retail. Se aplicaron técnicas de preprocesamiento, transformación y minería de datos con el objetivo de predecir si una transacción es rentable. Se compararon dos algoritmos de clasificación: Árbol de Decisión y Naive Bayes. El modelo basado en Árboles de Decisión mostró mejor rendimiento general con un F1-score de 0.97. Finalmente, se proponen recomendaciones de negocio basadas en los hallazgos.

Palabras clave

Minería de datos, clasificación, árbol de decisión, Naive Bayes, inteligencia de negocios, análisis de rentabilidad.

1. Introducción

El análisis de la rentabilidad en ventas es un tema central en la inteligencia de negocios. Comprender qué factores influyen en que una venta sea rentable permite a las empresas optimizar sus estrategias comerciales. Este proyecto utiliza un dataset de ventas minoristas (Superstore) para construir modelos predictivos que determinen si una venta es rentable. Se aplican técnicas de clasificación con enfoque en dos algoritmos principales: Árboles de Decisión y Naive Bayes.

2. Metodología

2.1 Selección del Dataset

Se utilizó el dataset Sample - Superstore con 9994 registros y 21 columnas. Contiene información sobre ventas, productos, clientes y ganancias.

2.2 Preprocesamiento


Se eliminaron valores nulos y duplicados. Las variables categóricas fueron transformadas mediante codificación (get_dummies). Las variables numéricas fueron estandarizadas.

2.3 Transformación y Variable Objetivo


Se creó la variable binaria 'Rentable', donde 1 representa una venta con ganancia positiva y 0 representa pérdida.

2.4 Visualización de Datos


A continuación, se muestran algunos gráficos exploratorios que permitieron comprender mejor el comportamiento de los datos.



[Figura 1: Distribución del Profit]



[Figura 2: Ganancia por Categoría]



[Figura 3: Relación entre Descuento y Ganancia]

3. Modelado y Clasificación

Se aplicaron dos algoritmos de clasificación:

- Árbol de Decisión (DecisionTreeClassifier)
- Naive Bayes (GaussianNB)

El dataset fue dividido en 70% entrenamiento, 15% validación y 15% prueba. La métrica objetivo es la predicción binaria de rentabilidad.

[Listing 1: División del dataset en train, validación y test]


[Listing 2: Entrenamiento de Árbol de Decisión]

[Listing 3: Entrenamiento de Naive Bayes]


4. Evaluación y Resultados

Se utilizaron las métricas Accuracy, Precision, Recall y F1-score para evaluar ambos modelos.

Modelo	Accuracy	Precision	Recall	F1-score
Árbol de Decisión	0.949	0.962	0.976	0.969
Naive Bayes	0.899	0.889	0.999	0.941



[Figura 4: Matriz de Confusión - Árbol de Decisión]



[Figura 5: Matriz de Confusión - Naive Bayes]

5. Conclusiones y Recomendaciones

El análisis desarrollado permitió predecir la rentabilidad de ventas utilizando algoritmos de clasificación aplicados al conjunto de datos “Superstore”. Los principales hallazgos son los siguientes:

- El modelo basado en Árbol de Decisión presentó el mejor desempeño global, alcanzando un F1-score de 0.969, superior al modelo Naive Bayes.
- El atributo "Discount" demostró tener una correlación negativa significativa con la rentabilidad; los niveles de descuento elevados tienden a generar pérdidas.
- Ciertas subcategorías, particularmente dentro de la categoría "Furniture", presentan mayor probabilidad de ventas no rentables, especialmente cuando se asocian con tipos de envío costosos.

Desde una perspectiva de inteligencia de negocios, los modelos desarrollados pueden ser integrados en sistemas de gestión para predecir la rentabilidad antes de concretar una venta, facilitando la toma de decisiones operativas.

Se proponen las siguientes recomendaciones:

- Establecer un umbral máximo para descuentos, particularmente en productos de baja rotación.
- Revisar las políticas logísticas asociadas a los métodos de envío que incrementan los costos.
- Incorporar el modelo predictivo en procesos de preventa como herramienta de apoyo a la gestión comercial.

Utilizar plataformas de visualización como Power BI para monitorear continuamente los patrones de rentabilidad y ajustar estrategias.

6. Referencias

- [1] Scikit-learn developers, “Scikit-learn: Machine Learning in Python,” [Online]. Available: <https://scikit-learn.org>. [Accessed: 3-May-2025].
- [2] IEEE Latin America Transactions, “Author Guidelines,” [Online]. Available: <https://latamt.ieee9.org/index.php/transactions/about/submissions>. [Accessed: 3-May-2025].
- [3] Minería de Datos, Módulo de Postgrado, Universidad Mayor de San Andrés, 2025.

7. Anexos

Repositorio del Proyecto en GitHub

El código fuente, dataset, dashboard y documentación se encuentran disponibles en el siguiente repositorio:
<https://github.com/percypedro/clasificacion-rentabilidad-superstore-Postgrado-Percy-Fuentes>


Código fuente en Jupyter Notebook

El análisis completo fue desarrollado en Python y está disponible como archivo .ipynb en la carpeta raíz del repositorio.

Dataset utilizado

Se utilizó el dataset “Sample - Superstore” proporcionado por Tableau. El archivo original está incluido en el repositorio para referencia académica.

Dashboard en Power BI



[Figura 6: Dashboard de rentabilidad]

Archivo del Dashboard

El archivo .pbix se encuentra disponible en el repositorio para su visualización y edición en Power BI Desktop.